

Proyecto final de Optimización Convexa

Optimización de hiperparámetros en modelos predictivos

Acoyani Garrido Sandoval

17 de mayo de 2026

1. Introducción

El objetivo del presente proyecto final es aplicar los conceptos aprendidos en el curso de Optimización Convexa para resolver un problema de optimización de hiperparámetros en un modelo predictivo.

En general, los pasos del proyecto son:

1. Seleccionar un problema de aprendizaje supervisado o no supervisado. Puede ser uno que esté siendo desarrollado, o que tenga relevancia personal o académica.
2. Elegir modelos base que tengan hiperparámetros susceptibles de ser optimizados.
3. Identificar los hiperparámetros críticos del modelo y definir un espacio de búsqueda adecuado para cada uno de ellos.
4. Plantear el problema de buscar los valores de los hiperparámetros como un problema de optimización: regularización L1, L2 o *elasticnet*, conjuntos convexos y restricciones, minimización de funciones convexas, dualidad y condiciones de optimalidad, o métodos de optimización tales como gradiente descendente.
5. Implementar la solución del problema en una Jupyter notebook. Está permitido el uso de librerías, siempre y cuando se justifique el método de optimización.

2. Selección de conjunto de datos

El conjunto de datos usado para estos fines es el **Telco Customer Churn** (Kaggle, 2018), un conjunto de datos desarrollado por IBM originalmente como una muestra de datos incluída con el software **IBM Cognos Analytics Server** (IBM, 2026), un software de análisis y visualización de datos basado en Java Enterprise Edition. Este conjunto de datos reviste una doble importancia personal para mí, ya que por una parte se trata de un conjunto de datos relacionado con comportamiento de clientes, giro en el cual actualmente manejo un negocio denominado **BuzónQR®**; y por otro lado, por el hecho de ser un conjunto de datos inicialmente concebido para probar las capacidades del software IBM Cognos Analytics Server, una plataforma de inteligencia de negocios inicialmente desarrollada por la empresa canadiense Cognos que fue comprada por IBM hacia el año 2008, orientada principalmente a visualización, procesamiento, análisis y exploración de datos; mi primer trabajo, el cual desempeñé en IBM desde 2012 hasta 2018, fue como administrador de una serie de instancias de dicha plataforma.

2.1. Características del conjunto de datos

El conjunto de datos *Telco Customer Churn* tiene como finalidad ofrecer un medio para mejorar la retención de clientes a través de información acerca de ellos y un dato que muestra si han dejado la empresa de telefonía en el último mes.

En este conjunto de datos, cada fila representa uno de los usuarios de la empresa de telefonía, y cada columna representa información acerca del cliente. Las características de este modelo son:

1. **Variable dependiente:** *Churn*. Es una variable binaria cuyos valores son “Yes” o “No”, e indica si el cliente ha dejado la compañía en el último mes. La distribución de clases de esta variable es de 73.5 % retenidos ($\Pr(Churn = No)$) y 26.5 % no retenidos ($\Pr(Churn = Yes)$); está moderadamente desbalanceado, lo cual es importante a la hora de elegir hiperparámetros de ponderación de clase.
2. **Características:** Encuadran en 4 grupos naturales: **demográficas** (*gender*, *SeniorCitizen*, *Partner*, *Dependents*), **información de cuenta** (*tenure* (meses como cliente), *Contract* (mensual, anual, bienal), *PaperlessBilling*, *PaymentMethod*), y **servicios suscritos** (*PhoneService*, *MultipleLines*, *InternetService*, *OnlineSecurity*, *OnlineBackup*, *DeviceProtection*, *TechSupport*, *StreamingTV*, *StreamingMovies*), y **cargos** (*MonthlyCharges*, *TotalCharges*).

Si realizamos un proceso de *one-hot encoding* de las características (descrito más adelante), obtenemos un total de 30 dimensiones de datos; lo cual implica que será necesario elegir características a través de la regularización, a la

vez que la cantidad de características es lo suficientemente pequeña para que un solver convexo lo pueda resolver.

En general, podemos observar que se trata de un problema de clasificación supervisada binaria, lo cual hace que el modelo natural a elegir sea **regresión logística**. Además de prestarse de forma natural a variables dependientes binarias, este modelo tiene 3 características que van en línea con el contenido del curso:

1. La regresión logística tiene una función de log-verosimilitud negativa convexa en parámetros, lo que hace que la superficie de pérdida tenga un mínimo global único.
2. Añadir regularización L1, L2 o elasticnet preservará la convexidad, lo que nos permitirá aplicarlas sin complejidades.
3. El problema de optimización tiene un planteamiento dual y condiciones KKT bien conocidas.

2.2. One-hot encoding de características

En la subsección anterior, mencioné que un proceso de *one-hot encoding* de las características arrojó 30 dimensiones de datos. El proceso para hacer eso y las implicaciones se explican a continuación.

Proceso Consiste en...

3. Desarrollo del problema

Habiendo expuesto la composición de nuestro conjunto de datos, la metodología que seguiremos será:

1. **Planteamiento del problema:** Predecir $\Pr(\text{Churn} = 1|x)$ a partir de las características de los clientes.
2. **Modelos:** Regresión logística como modelo primario, SVM lineal como modelo secundario. Compararé la pérdida logística contra la *hinge loss*. Privilegiaré el uso de modelos lineales con el fin de mantenernos en un marco de referencia convexo.
3. Plantear los hiperparámetros a optimizar y su espacio de búsqueda.
4. Plantear un problema de optimización convexa.
5. Implementación.

4. Desarrollo de la tarea

4.1. Inciso 1: Efecto de λ sobre el margen y las variables de holgura

El parámetro $\lambda > 0$ actúa como un **factor de escalamiento de las variables de holgura** dentro de la restricción de clasificación. Reescribiendo la restricción modificada como

$$y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \lambda \xi_i,$$

se observa que cada unidad de holgura ξ_i relaja el margen funcional en una cantidad $\lambda \xi_i$. Es decir, λ controla la *eficacia con la que cada unidad de holgura reduce el margen requerido*.

Caso $\lambda \rightarrow 0^+$: La restricción tiende a $y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1$ independientemente del valor de ξ_i . Esto significa que las variables de holgura pierden todo su poder de relajación: por más grande que sea ξ_i , la restricción dura sigue exigiendo una clasificación correcta con margen unitario. El problema degenera al **SVM de margen duro**, que es infactible cuando los datos no son linealmente separables. Además, como ξ_i ya no relaja nada pero sigue penalizándose con $C\xi_i$ en el objetivo, la solución óptima fija $\xi_i^* = 0$ siempre que sea factible.

Caso $\lambda \rightarrow \infty$: Una holgura ξ_i infinitesimal basta para satisfacer la restricción, pues $\lambda \xi_i$ se vuelve arbitrariamente grande. La restricción se vuelve **trivialmente satisfacible**: incluso para puntos mal clasificados, un valor pequeño de ξ_i es suficiente. En el límite, la restricción deja de ser activa y el problema se reduce a minimizar $\frac{1}{2}\|\mathbf{w}\|^2 + C\sum_i \xi_i$ con la solución trivial $\mathbf{w}^* = 0$, $\xi_i^* = 0$, lo cual corresponde a un **clasificador degenerado** sin capacidad discriminativa.

Impacto sobre el problema de optimización: En la formulación dual (que se obtendrá en el inciso 5), λ aparece modificando la cota superior de los multiplicadores de Lagrange como $0 \leq \alpha_i \leq C/\lambda$. De manera que:

- Valores pequeños de λ permiten multiplicadores α_i grandes, dando *más peso* a los vectores de soporte y produciendo un margen más estricto.
- Valores grandes de λ restringen fuertemente a los α_i , lo que se traduce en un clasificador con menor influencia de los puntos individuales y por tanto un *margen más amplio pero con más violaciones permitidas*.

En síntesis, λ actúa de manera *opuesta* a C : incrementar λ es cualitativamente equivalente a disminuir el costo efectivo de la holgura.

4.2. Inciso 2: Formulación del Lagrangiano

El problema primal es:

$$\begin{aligned} \min_{\mathbf{w}, b, \boldsymbol{\xi}} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \\ \text{s.a.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1 + \lambda \xi_i \geq 0, \quad i = 1, \dots, n, \\ & \xi_i \geq 0, \quad i = 1, \dots, n. \end{aligned}$$

Asociando los multiplicadores de Lagrange $\alpha_i \geq 0$ a las restricciones de clasificación y $\mu_i \geq 0$ a las restricciones de no-negatividad de las holguras, el Lagrangiano queda:

$$\mathcal{L}(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i [y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1 + \lambda \xi_i] - \sum_{i=1}^n \mu_i \xi_i.$$

(1)

4.3. Inciso 3: Condiciones de Karush-Kuhn-Tucker (KKT)

Las condiciones KKT del problema modificado son:

(a) **Estacionariedad** (gradiente nulo respecto a las variables primales):

$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i = \mathbf{0}, \quad (2)$$

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^n \alpha_i y_i = 0, \quad (3)$$

$$\frac{\partial \mathcal{L}}{\partial \xi_i} = C - \lambda \alpha_i - \mu_i = 0, \quad i = 1, \dots, n. \quad (4)$$

(b) **Factibilidad primal:**

$$y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1 + \lambda \xi_i \geq 0, \quad i = 1, \dots, n, \quad (5)$$

$$\xi_i \geq 0, \quad i = 1, \dots, n. \quad (6)$$

(c) **Factibilidad dual:**

$$\alpha_i \geq 0, \quad i = 1, \dots, n, \quad (7)$$

$$\mu_i \geq 0, \quad i = 1, \dots, n. \quad (8)$$

(d) **Holgura complementaria:**

$$\alpha_i [y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1 + \lambda \xi_i] = 0, \quad i = 1, \dots, n, \quad (9)$$

$$\mu_i \xi_i = 0, \quad i = 1, \dots, n. \quad (10)$$

4.4. Inciso 4: Relaciones entre $\mathbf{w}$, b y ξ

A partir de las condiciones de estacionariedad obtenidas en (1)–(3) se deducen las siguientes relaciones primales-duales fundamentales:

Relación para $\mathbf{w}$: De $\partial\mathcal{L}/\partial\mathbf{w} = 0$ se obtiene

$$\boxed{\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i.} \quad (11)$$

El vector óptimo $\mathbf{w}$ es una combinación lineal de los puntos de entrenamiento, ponderados por su etiqueta y_i y su multiplicador α_i . Solo los puntos con $\alpha_i > 0$ (*vectores de soporte*) contribuyen.

Relación para b : De $\partial\mathcal{L}/\partial b = 0$ se obtiene la *condición de balance*

$$\boxed{\sum_{i=1}^n \alpha_i y_i = 0.} \quad (12)$$

Esta es una restricción lineal sobre los multiplicadores que garantiza que el problema dual sea consistente. El valor concreto de b se obtiene posteriormente mediante la holgura complementaria, evaluando la restricción activa en algún vector de soporte i^* con $0 < \alpha_{i^*} < C/\lambda$:

$$b = \frac{1 - \lambda \xi_{i^*}}{y_{i^*}} - \mathbf{w}^\top \mathbf{x}_{i^*}.$$

Relación para ξ : De $\partial\mathcal{L}/\partial\xi_i = 0$ resulta

$$\boxed{\mu_i = C - \lambda \alpha_i, \quad i = 1, \dots, n.} \quad (13)$$

Combinando con la factibilidad dual $\mu_i \geq 0$, se obtiene la **cota superior modificada** sobre los multiplicadores:

$$\boxed{0 \leq \alpha_i \leq \frac{C}{\lambda}, \quad i = 1, \dots, n.} \quad (14)$$

Esta es la diferencia clave respecto del SVM estándar (donde la cota es $\alpha_i \leq C$): el factor λ *reescala la cota superior* de los multiplicadores. Análisis adicional de la holgura complementaria $\mu_i \xi_i = 0$:

- Si $\alpha_i < C/\lambda$, entonces $\mu_i > 0$ y por holgura complementaria $\xi_i = 0$ (el punto está bien clasificado con margen ≥ 1).
- Si $\alpha_i = C/\lambda$, entonces $\mu_i = 0$ y ξ_i puede ser positivo (el punto puede estar dentro del margen o incluso mal clasificado).

4.5. Inciso 5: Derivación del problema dual

Sustituimos las relaciones de estacionariedad en el Lagrangiano para eliminar las variables primales. Partiendo de:

$$\mathcal{L} = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_i \xi_i - \sum_i \alpha_i y_i \mathbf{w}^\top \mathbf{x}_i - b \sum_i \alpha_i y_i + \sum_i \alpha_i - \lambda \sum_i \alpha_i \xi_i - \sum_i \mu_i \xi_i.$$

Paso 1: Eliminar el término en b . Por la condición $\sum_i \alpha_i y_i = 0$:

$$b \sum_i \alpha_i y_i = 0.$$

Paso 2: Eliminar los términos en ξ_i . Agrupando:

$$\sum_i (C - \lambda \alpha_i - \mu_i) \xi_i = 0,$$

ya que $C - \lambda \alpha_i - \mu_i = 0$ por la estacionariedad respecto de ξ_i .

Paso 3: Sustituir $\mathbf{w}$. Usando $\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$:

$$\begin{aligned} \|\mathbf{w}\|^2 &= \mathbf{w}^\top \mathbf{w} = \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j, \\ \sum_i \alpha_i y_i \mathbf{w}^\top \mathbf{x}_i &= \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j. \end{aligned}$$

Por lo tanto:

$$\frac{1}{2} \|\mathbf{w}\|^2 - \sum_i \alpha_i y_i \mathbf{w}^\top \mathbf{x}_i = -\frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j.$$

Función objetivo dual. Reuniendo todos los términos sobrevivientes:

$$\boxed{\mathcal{D}(\boldsymbol{\alpha}) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j.} \quad (15)$$

Restricciones del dual. Los multiplicadores deben cumplir:

$$\begin{aligned} \sum_{i=1}^n \alpha_i y_i &= 0, \\ 0 &\leq \alpha_i \leq \frac{C}{\lambda}, \quad i = 1, \dots, n. \end{aligned}$$

Problema dual completo. El problema dual del SVM con margen suave modificado es por tanto:

$$\begin{array}{ll}
\max_{\alpha} & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j \\
\text{s.a.} & \sum_{i=1}^n \alpha_i y_i = 0, \\
& 0 \leq \alpha_i \leq \frac{C}{\lambda}, \quad i = 1, \dots, n.
\end{array} \tag{16}$$

Observación final. La forma del dual es estructuralmente idéntica al SVM estándar, con la única diferencia de que la **cota superior de los multiplicadores cambia de C a C/λ** . Esto confirma cuantitativamente la intuición del inciso 1: el efecto de λ es equivalente a reescalar el parámetro de regularización efectivo $C_{\text{eff}} = C/\lambda$. Por tanto, esta modificación no introduce nueva expresividad al modelo — es matemáticamente equivalente a usar un SVM estándar con un parámetro C escalado —, lo cual es un resultado teóricamente interesante.

5. Conclusiones

A lo largo de esta tarea se desarrolló completamente la teoría dual del SVM con margen suave modificado mediante el factor λ . Los resultados principales son:

- El parámetro λ controla la eficacia con que la holgura relaja el margen, actuando opuestamente al parámetro C .
- La estructura de las condiciones KKT es análoga al caso estándar, con la única modificación de la condición de estacionariedad respecto de ξ_i , que pasa de $C - \alpha_i - \mu_i = 0$ a $C - \lambda\alpha_i - \mu_i = 0$.
- Esto se traduce en una cota superior modificada $\alpha_i \leq C/\lambda$ en el dual.
- La función objetivo dual permanece idéntica al caso estándar, lo que demuestra que la modificación es equivalente a un reescalamiento del parámetro de regularización: $C_{\text{eff}} = C/\lambda$.

Referencias

- IBM (2026). Ibm cognos analytics. <https://www.ibm.com/products/cognos-analytics>. Consultado en Kaggle el 16 de Mayo de 2026.
- Kaggle (2018). Ibm telco customer churn dataset. <https://www.kaggle.com/datasets/blastchar/telco-customer-churn/data>. Consultado en Kaggle el 16 de Mayo de 2026.