

Actividad de Clase — Optimización Convexa

SVR L1 y L2 con outliers: análisis teórico, sensibilidad y robustez

Resumen

Este reporte aborda la regresión por máquinas de soporte vectorial (SVR) con pérdidas L1 (ϵ -insensible) y L2 (ϵ -insensible cuadrática). Sobre un conjunto sintético no lineal $y = \sin(x) + 0.5 \cdot \cos(2x) + \eta$ con $\eta \sim N(0, 0.3^2)$, se entrenan modelos SVR-L1 (RBF), SVR-L2 (RBF aproximado), SVR lineal y SVR-L1 RBF con hiperparámetros óptimos por GridSearchCV, en versiones limpia y contaminada con outliers. Se realiza barrido de $C \in [0.01, 100]$ y de $\epsilon \in [0.01, 1.5]$, y un experimento de robustez incrementando los outliers de 0 a 20. Los resultados confirman: (i) C controla el compromiso sesgo-varianza y, en el límite $C \rightarrow \infty$, el problema converge a interpolación exacta; (ii) ϵ controla la dispersión de la solución, produciendo soluciones con menos vectores de soporte conforme crece; (iii) la pérdida L1 es notablemente más robusta a outliers que la L2, cuya magnitud crece cuadráticamente con el residuo.

1. Marco teórico

1.1 Formulación primal de SVR

El problema primal de SVR-L1 (ϵ -insensible) en un espacio de características $\phi(x)$ es:

$$\begin{aligned} \min_{w, b, \xi, \xi^*} \quad & \frac{1}{2} \|w\|^2 + C \cdot \sum_i (\xi_i + \xi_i^*) \\ \text{sujeto a: } & y_i - (w^T \phi(x_i) + b) \leq \epsilon + \xi_i, \quad (w^T \phi(x_i) + b) - y_i \leq \epsilon + \xi_i^*, \quad \xi_i, \xi_i^* \geq 0. \end{aligned}$$

La variante L2 reemplaza la suma de holguras por su versión cuadrática $C \cdot \sum_i (\xi_i^2 + \xi_i^{*2})$, eliminando además la restricción $\xi_i, \xi_i^* \geq 0$ al ser absorbida por la cuadratura.

1.2 Dual y vectores de soporte

Aplicando Lagrange y las condiciones KKT, se llega al dual de SVR-L1:

$$\begin{aligned} \max_{\alpha, \alpha^*} \quad & -\frac{1}{2} \sum_{i,j} (\alpha_i - \alpha_i^*)(\alpha_j - \alpha_j^*) k(x_i, x_j) - \epsilon \sum_i (\alpha_i + \alpha_i^*) + \sum_i y_i (\alpha_i - \alpha_i^*) \\ \text{sujeto a: } & 0 \leq \alpha_i, \alpha_i^* \leq C \text{ y } \sum_i (\alpha_i - \alpha_i^*) = 0. \end{aligned}$$

La predicción es $f(x) = \sum_i (\alpha_i - \alpha_i^*) k(x_i, x) + b$. Los **vectores de soporte** son los puntos con $\alpha_i - \alpha_i^* \neq 0$; por las condiciones KKT, esto ocurre exactamente cuando $|y_i - f(x_i)| \geq \epsilon$.

2. Parámetro C: regularización vs ajuste

2.1 Relación entre C y el número de vectores de soporte

C es el peso del término de pérdida frente al de regularización $\frac{1}{2} \|w\|^2$. En el dual, su efecto es la cota superior $0 \leq \alpha_i, \alpha_i^* \leq C$. Cuando C es pequeño, la cota es restrictiva: muchos α_i tienden a saturarse en cero (al permitirse violaciones del tubo sin penalizar), por lo que el modelo tolera mucho error y el número de vectores de soporte puede ser *alto* (todos los puntos fuera del tubo entran como SV con $\alpha_i = C$). Por el contrario, cuando

C es grande, el optimizador prefiere ajustar tanto como sea posible: muy pocos puntos quedan fuera del tubo y, aunque cada uno puede tener α grande, el *número total* de SV se reduce. La **Figura 2** confirma esta tendencia: el #SV decrece de ~63 (C=0.01) a ~44 (C=10) en SVR-L1.

Sobreajuste con C grande: al hacer $C \rightarrow \infty$ se elimina la regularización: $\|w\|^2$ ya no penaliza, por lo que el modelo puede elegir w de norma arbitrariamente grande para forzar todos los residuos a quedar dentro del tubo (o a ser cero, en el caso L2 sin tubo). Esto memoriza el ruido de entrenamiento y, ante outliers, deforma la función ajustada cerca de ellos.

2.2 Demostración: $C \rightarrow \infty$ conduce a interpolación exacta

Considérese el primal de SVR-L1 con $\varepsilon=0$ (sin tubo). El problema es:

$$\min \frac{1}{2} \|w\|^2 + C \cdot \sum (\xi_i + \xi_i^*) \text{ con } |y_i - f(x_i)| \leq \xi_i + \xi_i^*.$$

Sea f_C^* el óptimo. Definimos $\psi(C) := \min_f \{ \frac{1}{2} \|w\|^2 / C + \sum |y_i - f(x_i)| \}$, equivalente al problema original tras dividir entre C. Cuando $C \rightarrow \infty$, el factor $\frac{1}{2} \|w\|^2 / C \rightarrow 0$ para cualquier w finito, y el problema se reduce a:

$$\min_{f \in H} \sum_i |y_i - f(x_i)|$$

donde H es el espacio de Hilbert de núcleo reproducible (RKHS) asociado a $k(\cdot, \cdot)$. Si k es un kernel universal (como el RBF) y los x_i son distintos, la matriz $K = [k(x_i, x_j)]$ es definida positiva y existe una función $f \in H$ tal que $f(x_i) = y_i \forall i$. Por tanto, el mínimo es 0 y se alcanza con interpolación exacta. Para $\varepsilon > 0$ fijo el argumento es análogo: el límite es interpolación dentro del tubo (todos los residuos $\leq \varepsilon$), que en el caso ε pequeño se acerca tanto como se desee a la interpolación exacta. En la **Figura 6** se observa cómo, al pasar de C=0.01 a C=10 000, el ajuste pasa de una casi-constante a una curva que sigue de cerca cada punto de entrenamiento, incluyendo los outliers, lo que valida empíricamente este resultado.




Figura 1. Efecto del parámetro C sobre el ajuste SVR-L1 (RBF). Para C pequeño la regularización domina y el modelo es casi plano; para C grande el modelo tiende a interpolar los puntos.

3. Parámetro ε : ancho del tubo y dispersión

3.1 Efecto de ε sobre la complejidad del modelo

ε define el ancho del tubo de insensibilidad: ningún error $|y_i - f(x_i)| \leq \varepsilon$ contribuye a la pérdida. Aumentar ε **reduce la complejidad efectiva** del modelo porque (a) más puntos quedan dentro del tubo y no son SV, y (b) la función ajustada puede ser más suave. La **Figura 3** muestra que el #SV cae de 79 ($\varepsilon=0.01$, casi todos los puntos son SV) a apenas 5 cuando $\varepsilon=1.5$, y el MSE sube monótonicamente porque el modelo se vuelve demasiado tolerante.

$\varepsilon \rightarrow 0$: el tubo desaparece. Cada error penaliza linealmente (L1) o cuadráticamente (L2). El modelo intenta ajustarse a todos los puntos: casi todos son SV, la solución pierde dispersión y se comporta como una regresión kernel ridge (L2) o por mínima desviación absoluta (L1).

$\varepsilon \rightarrow \infty$: todos los puntos caen dentro del tubo, ningún error penaliza y la pérdida se anula. Para ε suficientemente grande, la solución óptima es $f(x) \equiv b$ (constante igual a la mediana / media de y), con cero vectores de soporte y el sesgo más alto posible.

3.2 ε y dispersión (sparsity) de la solución

Por las condiciones KKT del dual L1: $\alpha_i(\varepsilon + \xi_i - y_i + f(x_i)) = 0$ y α_i^* análogo. Esto implica que $\alpha_i > 0$ sólo si $y_i - f(x_i) = \varepsilon + \xi_i$, es decir, si el punto está sobre la frontera del tubo o fuera. Todos los puntos estrictamente dentro del tubo tienen $\alpha_i = \alpha_i^* = 0$ y **no participan en la predicción**: $f(x) = \sum_{i \in \text{SV}} (\alpha_i - \alpha_i^*) k(x_i, x) + b$. Esto es la **solución dispersa**: cuanto mayor el ε , mayor la fracción de puntos dentro del tubo y más dispersa la representación. La Figura 3 lo confirma: pasar de $\varepsilon=0.01$ a $\varepsilon=0.5$ reduce los SV del 99 % al 18 % de los puntos.

4. Resultados experimentales

4.1 Diseño experimental

Función verdadera: $y = \sin(x) + 0.5 \cdot \cos(2x)$, $x \in [-4, 4]$; ruido gaussiano $\sigma=0.3$; $n_{\text{train}}=80$, $n_{\text{test}}=200$; semilla=42. Versión con outliers: dos puntos a los que se les suma ± 3.0 (errores $|\Delta y| \geq 2.5$). Modelos: SVR-L1 (RBF), SVR-L2 (RBF aproximado por RBFsampler + LinearSVR con loss squared_epsilon_insensitive), SVR lineal (LinearSVR), y SVR-L1 RBF óptimo (GridSearchCV sobre C , ϵ , γ). Hiperparámetros iniciales: $C=1$, $\epsilon=0.2$, $\gamma=0.5$.

4.2 Cuadrícula 2x4: modelos x datasets




Figura 2. Ajustes para los cuatro modelos sobre el dataset limpio (arriba) y con dos outliers (abajo). Línea sólida: $f(x)$ ajustada; líneas punteadas: tubo $\pm \epsilon$; línea gris: f verdadera. Naranja: vectores de soporte. Gris claro: puntos dentro del margen. Rojo (x): outliers.

Modelo	Dataset	MSE_test	#SV (de 80)
SVR-L1 (RBF)	limpio	0.093	42
SVR-L1 (RBF)	con outliers	0.094	45
SVR-L2 (RBF)	limpio	0.105	45
SVR-L2 (RBF)	con outliers	0.153	55
SVR lineal	limpio	0.621	67
SVR lineal	con outliers	0.629	68
SVR-L1 óptimo (CV)	limpio	0.100	46
SVR-L1 óptimo (CV)	con outliers	0.091	79

Tabla 1. MSE en prueba y número de vectores de soporte para los 8 escenarios de la Figura 2.

Observaciones: con outliers, SVR-L1 mantiene el MSE prácticamente constante ($0.093 \rightarrow 0.094$), mientras que SVR-L2 se degrada un 46 % ($0.105 \rightarrow 0.153$). El SVR lineal ofrece el peor desempeño ($\text{MSE} \approx 0.62$) por

la insuficiente capacidad para una función no lineal. El modelo óptimo por CV con outliers eligió $C=1$, $\epsilon=0.01$, $\gamma=1.0$, lo que resulta en muchos SV (79/80) por usar un ϵ muy pequeño.

4.3 Barrido de C




Figura 3. Izquierda: MSE en prueba vs C (escala log). Derecha: número de vectores de soporte vs C. SVR-L1 (azul), SVR-L2 (rojo).

C	MSE L1	#SV L1	MSE L2	#SV L2
0.01	0.527	63	0.498	68
0.0278	0.381	60	0.373	63
0.0774	0.206	55	0.244	53
0.215	0.128	51	0.178	56
0.599	0.103	48	0.156	55
1.67	0.093	44	0.154	52
4.64	0.092	44	0.160	48
12.9	0.100	44	0.169	48
35.9	0.100	46	0.175	48
100	0.101	48	0.179	48

Tabla 2. Resultados del barrido de C (con outliers, $\epsilon=0.2$, $\gamma=0.5$).

Discusión: Para C pequeño (regularización fuerte) ambos modelos tienen MSE alto (~ 0.5) y muchos SV. Conforme C crece, el MSE de L1 disminuye rápidamente y se estabiliza alrededor de 0.10 desde $C \approx 1$. L2, en cambio, alcanza un mínimo cerca de $C \approx 1.7$ ($MSE \approx 0.15$) y luego empieza a **degradarse** al subir C: la pérdida cuadrática amplifica el efecto de los outliers cuando se permite menos regularización. En cuanto a #SV, L1 desciende de forma monótona hasta ~ 44 ; L2 (medido como puntos con residuo $> \epsilon$) se estabiliza en ~ 48 . La diferencia clave: L1 ofrece soluciones más dispersas y es más estable a C grandes, mientras L2 está más expuesta a deterioro por outliers.

4.4 Barrido de ϵ




Figura 4. Izquierda: MSE vs ϵ . Derecha: #SV vs ϵ . SVR-L1 (azul), SVR-L2 (rojo). $C=1$, $\gamma=0.5$, dataset con outliers.

ϵ	MSE L1	#SV L1	MSE L2	#SV L2
0.010	0.093	79	0.125	79
0.176	0.095	46	0.148	59
0.341	0.101	24	0.194	33
0.507	0.108	14	0.261	23
0.672	0.145	9	0.346	20
0.838	0.207	8	0.446	17
1.003	0.264	7	0.546	13
1.169	0.347	7	0.637	11
1.334	0.377	6	0.726	10
1.500	0.484	5	0.771	8

Tabla 3. Resultados del barrido de ϵ .

¿Existe ϵ óptimo? Para SVR-L1, el MSE mínimo se alcanza con $\epsilon \approx 0.01$ (MSE=0.093), pero el $\epsilon=0.18$ también es razonable (MSE=0.095) con sólo 46 SV en lugar de 79. Esto evidencia el compromiso **precisión vs. dispersión**. Para SVR-L2, el mínimo está en $\epsilon=0.01$ (MSE=0.125) y el desempeño se degrada más rápido al crecer ϵ . **El ϵ óptimo depende del modelo:** L1 tolera ϵ mayores antes de perder precisión porque los puntos fuera del tubo no son cuadráticamente penalizados.

5. Robustez frente al número de outliers




Figura 5. MSE en prueba en función del número de outliers (de 0 a 20). $C=1$, $\varepsilon=0.2$, $\gamma=0.5$.

#outliers	MSE L1	MSE L2
0	0.093	0.105
2	0.095	0.181
4	0.100	0.239
6	0.105	0.328
8	0.109	0.327
10	0.111	0.423
14	0.118	0.704
20	0.126	0.568

Tabla 4. Robustez: MSE en prueba vs número de outliers.

¿A partir de cuántos outliers SVR-L2 colapsa? Con sólo 2 outliers, SVR-L2 ya casi duplica el MSE (0.105 $\rightarrow$ 0.181). Con 6 outliers el MSE de L2 supera 0.3, y a partir de 10 outliers se observa **colapso visible** (MSE ≥ 0.42 , más de 4 $\times$ el de L1). En cambio, SVR-L1 apenas sube de 0.09 a 0.13 incluso con 20 outliers (un crecimiento total del 35 %). Esto es coherente con la teoría: la pérdida cuadrática asigna peso proporcional al cuadrado del residuo, por lo que un outlier con error Δ contribuye con $C \cdot \Delta^2$; en L1 contribuye sólo con $C \cdot \Delta$.

6. Kernel polinomial (grado 3) vs RBF




Figura 6. Comparación de SVR con kernel RBF y polinomial grado 3 sobre los datasets limpio y con outliers (mismos hiperparámetros: $C=1$, $\epsilon=0.2$, $\gamma=0.5$).

El kernel polinomial de grado 3 es claramente **insuficiente** para esta función, que tiene cuatro extremos en $[-4,4]$ (al contener $\cos(2x)$). Un polinomio de grado 3 sólo puede tener dos puntos críticos. El MSE del polinomial (≈ 0.64) es siete veces el de RBF (≈ 0.09). El comportamiento en los extremos del dominio es además inestable: los polinomios crecen sin cota fuera del rango de entrenamiento. El RBF, por su parte, es un **kernel universal**: puede aproximar cualquier función continua arbitrariamente bien sobre un compacto, lo que lo hace la elección natural para funciones no triviales.

7. ¿Por qué SVR-L2 no produce soluciones dispersas? (justificación matemática)

Para SVR-L2 (loss ϵ -insensible cuadrático), las restricciones de holgura $\xi \geq 0$ desaparecen y la pérdida es:

$$L_2(r) = \max(0, |r| - \epsilon)^2$$

El primal queda:

$$\min \frac{1}{2} \|w\|^2 + C \cdot \sum \xi_i^2 \text{ con } |y_i - f(x_i)| \leq \epsilon + \xi_i, \xi_i \in \mathbb{R}.$$

Las condiciones KKT producen el dual:

$$\begin{aligned} \max \quad & -\frac{1}{2} \sum (\alpha_i - \alpha_i^*) (\alpha_j - \alpha_j^*) k(x_i, x_j) - \epsilon \sum (\alpha_i + \alpha_i^*) + \sum y_i (\alpha_i - \alpha_i^*) - (1/4C) \sum (\alpha_i^2 + \alpha_i^{*2}), \\ \text{con sólo} \quad & 0 \leq \alpha_i, \alpha_i^* \text{ (sin cota superior } C). \end{aligned}$$

La diferencia clave está en la **relación entre α y la holgura**. En L1, KKT da: $\xi_i > 0 \Rightarrow \alpha_i = C$ (saturado), $\xi_i = 0$ y $|\text{residuo}| < \epsilon \Rightarrow \alpha_i = 0$ (cero exacto). Esto produce **dispersión**. En L2, la condición es $\alpha_i = 2C \xi_i$: α es **proporcional** al residuo. Como en general el residuo *nunca* es exactamente igual a ϵ en todos los puntos interiores (por la presencia de ruido y la naturaleza continua del problema), casi todos los puntos tienen $\xi_i \neq 0$.

y por tanto $\alpha_i \neq 0$. **Conclusión:** SVR-L2 no satisface las condiciones de complementariedad estricta que en SVR-L1 generan los $\alpha=0$ exactos; su solución es densa, todos los puntos contribuyen a la predicción.

8. Conclusiones

1. **Parámetro C:** compromete sesgo y varianza. $C \rightarrow 0$ da modelos planos y subajustados; $C \rightarrow \infty$ tiende a la interpolación exacta (memorización del ruido). Empíricamente, $C \approx 1-10$ funciona bien para esta función.
2. **Parámetro ϵ :** controla la dispersión. ϵ pequeño implica muchos SV (modelo denso, alta varianza); ϵ grande implica pocos SV y alto sesgo. $\epsilon \approx \sigma$ del ruido suele ser una elección razonable.
3. **L1 vs L2:** SVR-L1 es claramente **más robusta a outliers** y produce soluciones **dispersas**. SVR-L2 es preferible solo si se garantiza ausencia de outliers y se necesita una optimización más suave (loss diferenciable en todas partes).
4. **Kernel:** RBF es la elección estándar; polinomial requiere ajustar el grado a la complejidad real de la función y suele ser menos estable.
5. **Validación cruzada:** útil para encontrar buenos hiperparámetros, pero puede elegir configuraciones con muchos SV (ϵ pequeño) si el dataset tiene outliers, sacrificando dispersión por precisión.